

行业调研：外部存储与芯片内部存储在 AI 计算中心 (2026) 大规模建设中的机遇、挑战与投资价值

研究范围与证据框架

本报告把“外部存储”和“芯片内部存储”拆成两条同时被 AI 算力中心放大的主线：

第一，**芯片内部存储**（更准确地说是“靠近计算的存储/内存层”）：以 **HBM3E/HBM4/HBM4E** 为核心，外延到 GPU/CPU 的片上 SRAM 缓存、SoC/模块化 LPDDR（例如面向 AI 服务器的低功耗 LPDDR 模块方案）、以及围绕 **CXL** 的扩展/池化内存（“远内存/扩展内存”）。这一层的投资价值来自“带宽/容量/功耗”对训练与推理 ROI 的决定作用、以及供给侧极强的寡头性与工艺/封装门槛。¹

第二，**外部存储**（数据与模型资产的“数据湖→热数据→冷归档”全路径）：以数据中心 **NVMe SSD (PCIe Gen5/Gen6, QLC 高密度)** 与 **近线 HDD (HAMR/ePMR/UltraSMR)** 为两大底座，配合 NVMe-oF、并行文件系统/对象存储、以及 GPU 直连 I/O（例如 **GPUDirect Storage**）来“喂饱 GPU”。这一层的投资价值来自数据规模与数据复用（多模态、视频、生成内容）引发的容量爆发，以及“把 I/O 瓶颈变成算力浪费”的强激励。²

证据优先级上，本报告**强偏好第一手**：企业新闻稿/投资者资料/财报电话会文字稿与官方技术博客（例如 Micron Technology³ 的财报电话会准备稿、NVIDIA⁴ 的 CES 2026 与技术博客、Taiwan Semiconductor Manufacturing Company⁵ 的电话会纪要、Seagate Technology⁶ 与 Western Digital⁷ 的产品与路线公告等）。⁸

在“行业报告/媒体口径”上，本报告采取**交叉验证**：同一关键结论尽量同时由（1）公司一手材料、（2）至少一家主流通讯社或产业研究快讯、（3）技术联盟/论坛材料佐证。⁹

需求侧：2026 AI 计算中心建设带来的机遇、挑战与最可能技术路径

需求爆发的“第一性原理”与 2026 的核心矛盾

我对 2026 的强观点是：**AI 计算中心的瓶颈将从“有没有 GPU”快速迁移到“能不能把数据与能量高效率地送到 GPU 旁边”**。原因并不玄学，来自三条可量化的物理约束：

其一，**带宽墙 (HBM)**：面向“长上下文、MoE、agentic 推理”的工作负载，GPU 利用率越来越受“内存带宽 + 通信带宽 + I/O 路径”共同支配，而不仅是峰值算力。¹⁰

其二，**数据移动墙 (SSD/网络/CPU 旁路)**：当训练/推理流水线把“第一触达与最后触达数据”的环节搬到 GPU 上，传统 CPU bounce buffer 会直接吞噬带宽并放大延迟；因此绕过 CPU 的 GPU↔存储 DMA 路径会成为标配能力（这正是 GPUDirect Storage 的设计意图）。¹¹

其三，**功耗墙（HVDC + 1MW 机架 + BYOG）**：机架功耗迈向 600kW-1MW 级别时，54V 机架供电在“铜、空间、转换次数”上触到硬上限，因此行业在 2026-2027 会把高压直流（800VDC/±400VDC）推成事实标准；而电网容量与审批速度又迫使数据中心开发转向“自带发电”（BYOG/Bring Your Own Generation）甚至把电力系统当成并行建设的“第二条供应链”。¹²

在这种约束下，2026 的需求侧核心矛盾是：**算力中心扩建速度极快，但“HBM + 先进封装 + 电力交付”的供给弹性跟不上**。这会把“存储/内存”从传统配角推到 AI 基建的中心。¹³

2026 年 AI 基建“系统级技术路径”正在明确

2026 年最关键的系统信号来自 Rubin 平台的公开信息：它不是单一 GPU 升级，而是把**CPU、GPU、NVLink、网卡、DPU、以太网交换**当作“一台机架级超级计算机”共同设计，并明确把数据中心作为计算单元。¹⁴

Rubin 路线对“芯片内部存储/外部存储”行业的直接含义是：

芯片内部存储：HBM4 进入量产爬坡窗口

Rubin GPU 明确采用 HBM4，并给出极高的 HBM4 带宽指标（例如 Rubin GPU 的 HBM4 带宽达到 22 TB/s 级别），同时 NVLink 6 把 GPU-GPU 双向带宽抬到 3.6 TB/s/ GPU 的量级，整个 NVL72 机架被设计来服务通信/内存受限的 MoE 与推理路径。¹⁵

外部存储：PCIe Gen6 + GPU 直连 I/O 会把 SSD 从“配角”推成“系统约束”

Rubin 平台在系统层也把 PCIe Gen6 纳入主叙事（用于主机与设备整合），而数据中心 SSD 已经出现“PCIe Gen6 量产里程碑”：Micron 9650 被其官方博客定义为“世界首款 PCIe Gen6 数据中心 SSD 并已进入量产”，并给出 28GB/s 级别顺序读、5.5M IOPS 级别随机读等指标，同时强调“性能/能效/散热”成为 AI 存储设计一等约束。¹⁶

HVDC 与 BYOG 背景下，2026 的机遇与挑战

机遇：单位 MW 的“有效 Token/美元”驱动存储/内存升级

当行业进入“电力受限时代”，每多节省 1% 的端到端能效都能换来可量化的机架级算力/吞吐。NVIDIA 的 800VDC 架构文章直接把目标写成“支持 1MW 机架并自 2027 开始”，并给出对端到端效率、维护成本与总体拥有成本（TCO）的改善幅度预期；这会在 2026 形成一个非常强的工程路线：**先用侧车/电源机柜把高压直流引入数据厅，再逐步走向原生 HVDC 服务器**。¹⁷

机遇：近线 HDD 的“经济性回归”，成为 AI 数据湖的底座

Seagate 2026-03-03 公告称，其 Mozaic 4+（HAMR）平台已经在两家“领先超大规模云厂商”完成认证并进入生产部署，容量可达 44TB，并把“AI 规模数据增长的经济可行性”作为核心叙事；这等于在一手材料层面确认：**AI 的冷数据/历史档案/多模态内容会继续推高 HDD 的地位**。¹⁸

挑战：电力交付速度与合规把建设周期拉长，倒逼 BYOG

Mid-Atlantic 地区“BYOG（Bring Your Own Generation）”被明确提到：部分州长提出让数据中心开发商“自带发电”以换取更快的并网与审批，但其落地需要 PJM 规则与监管体系显著调整。这意味着 2026 的扩建将出现“双轨”：一轨是传统依赖电网扩容，另一轨是 BYOG/自建电源+储能的“快车道”。对存储/内存行业而言，结果通常是更“现金流确定”的订单模式（长协、预付款）以及更不均匀的区域建设节奏。¹⁹

2026 年正在被采用的技术清单

以下按“离算力远近”给出 2026 年主流在用技术（并强调哪些已进入一手材料确认状态）：

芯片内部存储（主流）

HBM3E：仍将是 2026 的主力形态。一方面，SK hynix 在其 2026 市场展望中明确写到“HBM3E 仍处于 2026 市场核心位置”，并引用外部机构预测其占比可能达到 2026 年 HBM 出货的约三分之二；另一方面，Micron 也在 Q1 FY2026 电话会准备稿中将 HBM 的增长定义为结构性，并强调 2026 的供需紧张。²⁰

HBM4：进入爬坡窗口。SK hynix 2025-09-12 新闻稿宣布“完成 HBM4 开发并已准备世界首个量产体系”，并披露关键工艺：2,048 I/O 端子、>10Gbps 速率、先进 MR-MUF 与 1b nm 级工艺；Samsung 亦在其新闻稿中披露“已出货商用 HBM4”，并给出 HBM4E 与定制 HBM 的采样时间点。²¹

外部存储（主流）

企业 NVMe SSD：在 AI 工作负载下，SSD 不再只是容量设备，而是数据流/检索增强（RAG）/长上下文推理的吞吐约束。Micron 在官方博客里把 PCIe Gen6 SSD 的量产与 AI 架构决策直接挂钩，并给出详细性能与能效指标；其财报准备稿亦明确“已推出全球首款 PCIe Gen6 SSD”，并提到高容量 QLC（122TB/245TB）进入超大规模客户验证。²²

近线 HDD：HAMR/ePMR/UltraSMR 等路线正在把单盘容量推到 40TB+。Seagate 明确表示 44TB HAMR 平台已在两家超大规模云厂商生产部署；WD 则公告其 40TB UltraSMR ePMR 盘“已在两家超大规模客户验证，计划 2026 下半年量产”，同时其 HAMR 计划在 2027 进入爬坡。²³

数据路径（2026 的“标配化”）

GPUDirect Storage：其官方文档将其定义为 GPU 内存与存储之间的 DMA 直通路，避免经 CPU 的 bounce buffer，以提升带宽并降低延迟与 CPU 负载；从投资角度看，这类能力会把“存储介质性能”与“系统软件栈/网卡/DPU”深度绑定，推动存储系统厂商进入“与 GPU 平台共研”的新范式。²⁴

新技术成熟与放量时间预测：在 Rubin、HVDC、BYOG 三条路径交汇下

下面给出我对“成熟时间（可规模化交付）”与“放量时间（需求曲线陡峭上升）”的判断。时间点以 2026 年为中心，且**偏乐观**（与用户对 AI 基建乐观预期一致）。关键事实均用一手材料锚定。

HBM4 放量

成熟时间：2025Q4–2026H1（供货体系成型）。SK hynix 已宣称完成开发并准备量产体系；Samsung 宣称已出货商用 HBM4。²¹

放量时间：2026H2–2027（与 Rubin 平台上架/出货共振）。NVIDIA 新闻稿称 Rubin 处于“full production”，合作伙伴产品将于 2026H2 可得；并列举多家云厂商与服务器 OEM 将在 2026 部署。²⁵

HBM4E 与定制 HBM

成熟时间：2026H2（样品与小规模验证）。Samsung 明确“HBM4E 将在 2026 下半年开始 sampling”；Micron 也在公开材料中提及 HBM4E 的定制化客户项目。²⁶

放量时间：2027（定制化从“项目”走向“产品线”）。Samsung 明确“custom HBM samples 2027”；这意味着 2027 起 HBM 的商业模式更像“ASIC 伴生件”，利润率更稳定、客户锁定更强。²⁷

SPHBM4 (“更便宜的 HBM4”路线)

成熟时间：2026-2027（标准接近定稿与样机验证阶段）。多家媒体报道 JEDEC 正推进 SPHBM4，通过更窄接口与串行化降低封装成本。²⁸

放量时间：更可能在 2028 前后。原因是它需要“控制器/封装/生态”三方重新协同，而 2026-2027 的产业注意力会被 HBM4/HBM4E 的供给爬坡与 Rubin 平台的系统验证占据（机会成本很高）。这一判断属于推断。²⁹

PCIe Gen6 数据中心 SSD 放量

成熟时间：2026（已有量产与客户验证信号）。Micron 官方博客称 9650 已进入量产，并强调“被关键 OEM 与 AI 数据中心客户验证”；其财报准备稿也把“全球首款 PCIe Gen6 SSD”作为数据中心组合拳的一部分。¹⁶

放量时间：2027（平台代际切换完成后）。原因是 SSD 放量取决于服务器 CPU 平台与交换/retimer 生态的成熟；在 Rubin 这一代，PCIe Gen6 被写进系统路径，2026H2 是“上架窗口”，2027 更像“扩散窗口”。³⁰

CXL 内存扩展/池化放量

成熟时间：2025-2026（生态与内核支持逐步落地）。CXL 联盟白皮书概述 CXL 3.1 的 fabric/安全/内存扩展增强；同时，CXL 相关会议材料展示在特定向量检索场景中，CXL 连接 DRAM 可带来最高 19% 的性能提升，并指出 Linux 主线内核已包含“weighted interleaving”能力。³¹

放量时间：2027（从“capable”到“enabled”）。CXL 的关键不是“有接口”，而是“软件栈/管理/可靠性”能否把它变成可运营资源。行业材料显示“CXL-capable server”比例上升很快，但“CXL-enabled server”提升更慢，2026 仍处于起步阶段。³²

HAMR 近线 HDD 放量

成熟时间：2026（生产部署已确认）。Seagate 明确 Mozaic 4+ 在两家超大规模云厂商生产部署，并计划扩大供给；WD 也把 2026H2 作为 40TB UltraSMR ePMR 的量产时间点。²³

放量时间：2026-2027（取决于“视频/多模态”的数据湖扩张）。Seagate 将 AI 训练数据、历史档案与 AI 生成内容（尤其视频/多模态）作为需求驱动；这类数据增长在 2026 具备强确定性（推断：模型能力越强→生成内容越多→归档/再训练越依赖低成本容量）。³³

HVDC（800VDC/±400VDC）与功率侧车

成熟时间：2026（从“参考设计/演示”转向“可采购产品”）。OCP 官方文章披露 Diablo 400 侧车把机架配电从 48V 提升到 ±400VDC/800VDC，覆盖 100kW-1MW；Advanced Energy 的 OCP Summit 观察则指出 HVDC 相关产品显著增多，并把 Rubin Ultra 机架的 MW 需求视作加速因素。³⁴

放量时间：2027（与 Kyber/更高功耗机架同频）。NVIDIA 官方技术博客直言：800VDC 的“full-scale production”将与 Kyber 机架级系统在 2027 同步。³⁵

2026 年最可能的技术路径判断

把上述时间轴合并，我对 2026 年最可能的行业技术路径给出结论（强观点）：

芯片内部存储：HBM3E“控场”，HBM4“上机架”，HBM4E/定制 HBM“立项锁客户”。

事实锚点是：Micron 将 HBM TAM 视作 2025-2028 的 40% CAGR 结构性增长，并确认 2026 HBM 供给已完成价格/数量协议；SK hynix 与 Samsung 分别释放了 HBM4 量产准备与 HBM4E sampling 时间点；而 Rubin 平台把 HBM4 写进系统并给出 2026H2 的伙伴供货窗口。³⁶

外部存储：PCIe Gen5 仍是主力出货，PCIe Gen6 在 2026 下半年开启“导入”，HAMR HDD 在 2026 实现“生产部署→扩散”。

事实锚点是：Micron 9650（Gen6）量产与验证信号；Seagate 44TB HAMR 生产部署；WD 40TB ePMR 2026H2 量产计划。³⁷

产业链：上下游拆解与不同上游所需产品、技术与供应链

为了匹配用户“特别关注不同上游”的要求，我用“链条分层 + 关键输入品”方式拆解，并把“外部存储”与“芯片内部存储”放在同一张产业地图里理解。

下游需求主体与采购形态

下游最关键的需求主体是：超大规模云、GPU 云（neocloud）、AI 研究/应用公司与大型企业自建 AI 工厂。NVIDIA 新闻稿列举了多个将在 2026 部署 Rubin 的云厂商与服务器 OEM，并点名一批基础设施软件与存储合作伙伴参与 Rubin 生态平台设计，这表明存储/内存将以“平台共研 + 生态认证 + 长协锁量”方式进入主流采购。³⁸

中游：可直接被“订单驱动”的产品层

芯片内部存储中游：

SK hynix³⁹、Samsung Electronics⁴⁰、Micron Technology³ 是 HBM 的核心供给方（市场份额数据常被引用：2025Q3 HBM 市占约 53%/35%/11%）。⁴¹

这一级产品形态包括 HBM3E/HBM4/HBM4E，以及围绕 base die/封装堆叠（MR-MUF 等）形成的“高价值工艺包”。⁴²

外部存储中游：

近线 HDD：Seagate 与 Western Digital 把 40-44TB 作为 2026 的关键容量台阶，其中 Seagate 已确认 44TB HAMR 平台在两家超大规模云厂商生产部署；WD 则确认 40TB UltraSMR ePMR 在两家超大规模客户验证并计划 2026H2 量产。²³

企业 SSD：在“性能 SSD（Gen6）+ 容量 SSD（QLC 122TB/245TB）”两条线上，Micron 已给出一手进展：Gen6 量产与验证、QLC 超大容量进入多家超大规模客户 qualification。⁴³

上游：按“不同上游行业”列出所需关键输入品

半导体制造与封装上游（HBM/先进封装共用）

先进封装（CoWoS 类 2.5D/3D）对 HBM 与 GPU 出货形成共同约束：TSMC 在电话会中反复强调“正在努力在 2026 增加 CoWoS 产能”，并将前后道 AI 相关产能形容为“非常紧”。⁴⁴

CoWoS 技术本身由 TSMC 官方页面定义为：通过硅中介层把逻辑芯片与 HBM 堆叠在同一封装中，以服务 AI/超算。⁴⁵

关键输入品与工序包括：

- TSV/堆叠/底部填充（例如 MR-MUF）与对翘曲控制、散热的工艺能力（SK hynix 在 HBM4 新闻稿中明确采用 Advanced MR-MUF，并解释其对量产稳定性的作用）。⁴⁶

- 先进封装产线设备与洁净室（Micron 明确表示新增洁净室空间是缓解 HBM 需求的必要条件，并指出全球洁净室建设交期在拉长）。⁴⁷

存储介质上游（NAND 与 HDD 供应链差异巨大）

NAND/SSD 的关键上游是 NAND 晶圆与控制器/互连生态。Micron 在官方博客里强调“PCIe Gen6 的互操作验证、retimer/switch 生态与散热升级（液冷进入存储）”，本质上意味着：SSD 的上游从单纯 NAND 走向“信号完整性+系统散热+互连器件”的复合供应链。⁴⁸

HDD（尤其 HAMR）的关键上游则包含“磁记录介质 + 精密机电 + 光子/激光/系统级控制”。Seagate 在 Mozaic 4+ 公告中用“垂直整合光子技术”来描述 HAMR 平台的生产级实现；WD 则把其路线拆成 ePMR→HAMR，并强调共用架构以提升制造效率与良率。²³

电力与数据中心物理基础设施上游（HVDC/BYOG）

OCP 的 Diablo 400 规范把 ±400VDC/800VDC 侧车定义为支撑 100kW-1MW 高密度机架的关键部件，并强调采用 400VDC 可复用电动车供应链；NVIDIA 的 800VDC 架构文章也列出合作的电力半导体与电源系统厂商类别。这意味着：AI 数据中心的供电升级会把电力电子（器件、模块、断路与保护、母排、线缆）变成新的“上游瓶颈候选”。

⁴⁹

市场规模与渗透：2026-2027 TAM/SAM/SOM 区间、公式、情景与触发信号

本节对“主流技术 + 快速增长新技术”给出 **TAM/SAM/SOM** 框架。所有数字尽量用一手材料锚定，再用情景假设扩展到区间。未能获得直接数据处，会明确用“乐观假设”补齐。

HBM（含 HBM3E/HBM4/HBM4E）

TAM（行业总规模）

Micron 在财报电话会准备稿中给出明确口径：HBM TAM 预计 2025 年约 350 亿美元，2028 年约 1000 亿美元，2025-2028 CAGR 约 40%，且 2028 的 HBM TAM 将超过 2024 全 DRAM 市场规模。⁵⁰

基于该口径，推导 2026-2027 TAM 区间（用 CAGR 作为中枢、加上区间波动）：

- 2026 TAM $\approx 350 \times (1.35-1.50) \approx$ **470-525 亿美元**（区间）

- 2027 TAM $\approx 2026 \times (1.30-1.50) \approx$ **610-790 亿美元**（区间）

交叉验证：SK hynix 的 2026 市场展望引用外部机构给出 2026 HBM 市场约 546 亿美元的估计，与以上区间一致。

⁵¹

SAM（可服务市场）

对“AI 计算中心”场景，HBM 的 SAM 近似等于 TAM（HBM 主要由 AI/HPC/高端加速器拉动）。保守估计也应在 **TAM 的 85%-95%**。这一判断是推断，但与 Micron 把 HBM/数据中心叙事绑定、并描述客户“AI 数据中心 build-out 计划推动需求激增”的一手表述一致。⁴⁷

SOM（可获得市场）

SOM 取决于投资标的定位：

- 若投资标的是 HBM 原厂：SOM $\approx$ 其产能份额（寡头结构下可达 10%-60%）。市场份额锚点可用 Reuters 引用 Counterpoint 的 2025Q3 份额数据。⁵²

- 若投资标的是 HBM 封装/测试/材料/设备：SOM≈“HBM 出货量 × 该环节单颗价值量 × 进入客户认证概率”。这一层往往更“高毛利但门槛更隐蔽”。 53

渗透率路径（HBM4 在 HBM 中的占比，2026–2027）

- 保守：2026 为 10%–20%，2027 为 25%–35%（HBM3E 长尾更长）
- 基准：2026 为 20%–30%，2027 为 35%–50%
- 乐观：2026 为 30%–40%，2027 为 50%–65%（Rubin 上架顺利且 HBM4 供给爬坡超预期）

关键触发信号

- Rubin 平台“合作伙伴产品 2026H2 可得”兑现进度与扩散速度。 54
- HBM4E sampling（2026H2）与定制 HBM（2027）从“新闻稿”走向“客户设计 win”。 55
- 供给侧紧张程度：Micron 明确“3-to-1 trade ratio（HBM 对 DDR5 的产能挤占）”与洁净室交期拉长，若这些约束缓解速度慢，HBM4 会更快穿透并获得更高 ASP。 56

PCIe Gen6 数据中心 SSD

TAM（行业总规模，按“性能 SSD”子市场定义）

为了可计算，我建议用“单位容量价值量 × 出货容量”做底层公式：

$$TAM_{Gen6\,SSD} = (\text{出货容量, TB}) \times (\text{ASP, \$ /TB})$$

其中出货容量可用“AI 服务器台数 × 每台 SSD 容量 × 采用 Gen6 比例”估算。Micron 官方资料给出“Gen6 SSD 量产 + 关键 OEM/AI 数据中心客户验证 + 28GB/s 指标”，这使得 2026 成为 Gen6 SSD 的导入年。 22

区间预测（偏乐观假设）

- 2026：**80–180 亿美元**（TAM，假设 Gen6 仍以性能盘为主、ASP/TB 高于 Gen5、且渗透率处于早期加速）
- 2027：**150–320 亿美元**（TAM，假设服务器平台 PCIe Gen6 生态成熟，推理侧 RAG/长上下文对本地/近端 SSD 的吞吐要求上升）

SAM（AI 计算中心可服务市场）

我更愿意用“AI 相关工作负载占性能盘需求比例”估算：

- 2026：SAM ≈ TAM × (60%–80%)
- 2027：SAM ≈ TAM × (70%–85%)

依据是 Micron 将“AI 训练/推理 + RAG/长上下文”直接作为 Gen6 SSD 的卖点与需求背景。 57

SOM（可获得市场）

- 控制器/retimer/switch/散热部件供应商的 SOM，常被“互操作认证+平台设计 win”决定；Micron 在博客中列举 DesignCon、FMS 2025、SC25 的生态演示与互操作里程碑，预示 2026–2027 认证价值飙升。 58

渗透率路径（Gen6 在数据中心 SSD 中的占比）

- 保守：2026 为 1%–3%，2027 为 5%–10%
- 基准：2026 为 3%–6%，2027 为 10%–18%
- 乐观：2026 为 6%–10%，2027 为 18%–30%（平台与供应链协同顺畅，且液冷/高密度存储成为新常态） 59

触发信号

- Gen6 SSD 从“少数旗舰客户验证”扩散到“多数 OEM 标配清单”。 58
- “液冷进入存储”从产品选项变成机架级标准设计（Micron 已在官方博客中点名该趋势）。 58

HAMR/ePMR/UltraSMR 近线 HDD

TAM（近线 HDD 的 AI 数据湖部分）

可用“新增冷数据容量 × \$ /TB”估算：

$$TAM_{Nearline} = (\Delta \text{Exabytes}) \times (10^6 \text{ TB} / \text{EB}) \times (\text{ASP}, \$ / \text{TB})$$

一手材料确认的关键是“40TB+ 作为 2026–2027 的主台阶”。Seagate 44TB 生产部署、WD 40TB 2026H2 量产计划与 2027 HAMR 爬坡，使得 2026 成为“容量拐点+成本下降”的起点。 23

区间预测（偏乐观假设）

- 2026：180–300 亿美元（TAM，假设 AI 视频/多模态带来冷数据激增，且 HDD 在“\$/TB”上仍显著优势）
- 2027：220–380 亿美元（TAM，假设 HAMR 扩散带来单位 TB 成本继续下降、部署速度加快）

市场结构与集中度锚点

HDD 行业集中度极高。Forbes 的 2025 年 HDD 行业更新给出单位出货份额约 42.3%（WD）、40.8%（Seagate）、17%（Toshiba）。 60

（注：Toshiba 61 在近线盘上更接近“第三极”，但定价权仍主要由双寡头主导，这是投资者要牢牢记住的“结构事实”。） 60

渗透率路径（HAMR 在近线 HDD 出货容量中的占比）

- 保守：2026 为 10%–20%，2027 为 20%–35%
- 基准：2026 为 20%–35%，2027 为 35%–55%
- 乐观：2026 为 35%–50%，2027 为 55%–75%（Seagate 已生产部署且扩产顺利，WD 跟进超预期） 23

触发信号

- Seagate “broader availability”是否在 2026 快速兑现。 62
- WD 40TB UltraSMR 的量产节奏与客户软件/业务层适配速度（SMR 对某些写入场景有约束）。 63

CXL 内存扩展/池化

TAM（按“Type-3 内存扩展设备/交换/管理软件”定义）

这类市场很容易被“capable vs enabled”误导。我建议把 TAM 分为两段：

- 1) 2026–2027 的 TAM 更像“试点→规模验证”的设备与软件订阅市场；
- 2) 真正放量在 2027 之后（更像基础设施层资产）。

渗透锚点来自 CXL 相关行业材料：到 2026 年，CXL-capable 服务器占比会非常高，但 CXL-enabled 仍处较低水平（图中 2026 约 1% 量级、2027 约 5% 量级）。 64

性能触发锚点：在向量检索（Milvus RAG cluster）示例中，CXL 连接 DRAM 带来最高 19% 性能提升，这类收益在 2026 的“RAG 工程化”大潮里具有可复制性。 65

供给侧：产能结构、瓶颈、成本与毛利演化

产能结构：集中在哪里、由谁掌控、卡在哪些工艺

HBM 产能结构（高度集中 + 工艺强耦合）

HBM 的供给侧高度集中在三家内存巨头，且份额长期由技术代际与客户认证决定。Reuters 引用 Counterpoint 的 2025Q3 份额为 53%/35%/11%。⁵²

HBM4 的工艺与量产风险被 SK hynix 在新闻稿中“讲透”：2,048 I/O、>10Gbps、先进 MR-MUF、1b nm 工艺，并强调 MR-MUF 的翘曲控制与量产稳定性价值。⁴⁶

先进封装产能结构（以 CoWoS 为代表，成为“总闸门”）

TSMC 对 CoWoS 的表态是：“仍在努力在 2026 增加产能”，且 AI 相关前后道产能都很紧。⁴⁴

结构含义：即便 HBM 与 GPU 晶圆产能具备，封装 slot 仍可能“卡住可交付 GPU 数量”，形成典型的“后道决定前道价值”的阶段。⁶⁶

HDD 产能结构（制造地集中 + 双寡头定价）

地理上，泰国长期是 HDD 生产枢纽。Reuters 报道泰国约占全球 HDD 供应约 80%，并披露 WD 在泰国扩产投资。⁶⁷

Seagate 也在其企业页面披露其制造站点覆盖多个国家（含马来西亚、新加坡、泰国等）。⁶⁸

供给瓶颈清单（至少五条，按“能否在 2026 解决”排序）

我把瓶颈分为“短期不可解（决定价格）”与“短期可缓解（决定份额）”。

短期不可解（2026 仍将紧张）

先进封装产能（CoWoS 类）：TSMC 明确 2026 仍在扩产且无法给出具体数字更新，反映供需缺口难以在短期抹平。⁶⁹

HBM 产能与洁净室交期：Micron 明确新增洁净室空间必要且交期拉长，并指出 HBM 对 DDR5 存在 3-to-1 trade ratio（产能挤占会随代际上升而加剧）。⁴⁷

客户认证与平台耦合：Rubin 生态以“平台共研/认证”方式组织，意味着新进入者很难在 2026 突破客户认证墙。⁷⁰

短期可缓解（2026 可能出现结构性机会）

PCIe Gen6 互连生态（retimer/switch/线缆/散热）：Micron 强调其过去 18 个月做了广泛互操作验证，并在多个论坛进行生态演示，意味着这一瓶颈更像“工程推进问题”，在 2026 可显著缓解并带来放量窗口。⁵⁸

HAMR 规模化制造与导入：Seagate 已确认生产部署与扩产路线，WD 给出明确量产时间点；换言之，2026 对 HAMR 更像“从技术可行到供应链可交付”的跨越。²³

电力交付与合规（BYOG/HVDC）：政策与标准正在形成（OCP Diablo、BYOG 提案），但落地取决于监管与工程组织；因此对“能提供交付确定性”的厂商而言，2026 反而是订单锁定与绑定客户的机会。⁷¹

成本与毛利：BOM/单位成本拆分、毛利决定因素、价格传导机制

HBM（高毛利、但被“良率+封装”支配）

单位成本拆分（概念性 BOM，适用于投资判断）：

- DRAM 晶圆与 die 成本（决定成本底座）
- TSV/堆叠与底填（决定良率与可靠性）
- Base die/金属化与测试（决定性能与客户认证）
- 封装（中介层/基板/翘曲控制/散热）与最终测试

毛利决定因素

- “供给是否被锁死”：Micron 已确认 2026 HBM 供给完成价格与数量协议，且供需紧张延续到 2026 之后；这类长协会显著稳定 ASP 与毛利。 50
- “代际领先是否可变现”：SK hynix 把 HBM4 的带宽提升、能效提升与量产工艺写成护城河；当客户进入 Rubin/HBM4 代际迁移，代际领先会直接反映为议价能力。 72

价格传导机制

- 从“现货周期”转向“长协/定制”：Micron 明确推动多年的“更强合同结构”与多年度承诺；Samsung 亦指向定制 HBM 的起步时间表。两者都意味着 HBM 的价格波动性在下降，而价值量在上升。 73

企业 SSD（性能盘进入“平台化定价”）

Micron 在 9650 的官方博客里强调“性能不再可选、存储是系统约束”，并给出“同功耗下 2 倍性能”等指标——这意味着性能盘的定价将越来越像“平台性能的一部分”，不再是简单的 $\backslash\$/TB$ 。 16

近线 HDD（容量升级带来“成本曲线”与“供给纪律”双重改善）

HAMR 的本质是“单位盘片面积存更多 bit”，带来 $\backslash\$/TB$ 与 W/TB 的改善。Seagate 将其 44TB HAMR 平台定位为支撑 AI 数据增长经济性的核心；WD 也强调 ePMR/HAMR 共用架构带来制造效率与良率改善。 23

竞争格局与壁垒：可量化结构、为什么能定价、价值捕获层判断

市场结构与头部集中度

HBM：典型寡头市场（“三家几乎全吃”）

供给集中度由 Reuters 引用的份额数据可直接量化：三家合计 $\approx 99\%$ （53%+35%+11%），且份额由代际与认证驱动。 52

先进封装（CoWoS 类）：高度集中（“一家公司像收费站”）

TSMC 的 CoWoS 供给紧张在其电话会中被反复提及，并构成 AI 芯片交付能力的核心约束之一。这个环节的集中度本身就构成定价权的来源。 66

近线 HDD：双寡头 + 第三极

Forbes 给出的 2025 年单位份额（WD $\approx 42.3\%$ 、Seagate $\approx 40.8\%$ 、Toshiba $\approx 17\%$ ）显示：供给端高度集中，且前两者对行业供给纪律与价格具有决定力。 74

壁垒清单：技术、规模、渠道/锁定、认证、切换成本

技术壁垒（为什么能定价）

HBM4 的技术壁垒是“系统性”的：接口宽度（2,048 I/O）、高 pin speed、堆叠翘曲控制、散热、可靠性与量产良率共同决定可交付性。SK hynix 直接把 MR-MUF、1b nm 工艺写入新闻稿，表明其壁垒不仅是设计，更是工艺与

制造 know-how。 46

HBM4 标准本身（JESD270-4）强调更高带宽、更多通道、更高堆叠与能效，这些指标天然推动“先进封装+信号完整性”门槛上移。 75

规模壁垒（资本开支与交付周期）

Micron 披露将 FY2026 CapEx 提升至约 200 亿美元，且新增产能要到 2027 之后才显著释放；SK hynix 亦在扩包装/测试与新厂，以适配 AI 内存需求。规模壁垒意味着 2026 仍是“卖方市场结构”。 76

渠道与客户锁定（平台共研 + 生态认证）

Rubin 生态把存储/基础设施软件伙伴拉进平台设计，意味着“被平台选中”本身就是渠道与锁定。对供应商而言，一旦进入下一代平台清单，复用周期通常是 2-4 年，并能在后续代际中延续。 70

认证标准与切换成本

- HBM：客户认证周期长，且涉及系统可靠性与良率稳定，切换风险极高。
- 企业 SSD：在 PCIe Gen6 时代，互操作/retimer/交换/散热形成一整套认证链条，一旦通过认证，替换会引发系统级再验证成本。 77
- 近线 HDD：超大规模客户对新记录技术导入（HAMR/SMR）需要数据布局、重写策略与系统级验证，切换成本同样不低。 23

价值捕获：哪一层最可能拥有长期高 ROIC/高毛利

我最看好的“长期高 ROIC/高毛利”层（排序）：

第一层：HBM（含定制 HBM4E）与其关键工艺/封装环节

理由：供给寡头 + 代际持续升级 + 定制化趋势把 HBM 从“周期品”拉向“类 ASIC 附属件”。Samsung 给出的 2027 定制 HBM sampling 时间表，强化了这一方向。 78

第二层：先进封装产能与关键材料/设备（CoWoS 类“收费站”）

理由：当 TSMC 自己在电话会中强调 2026 仍在追赶供给缺口，这个环节就很难变成“充分竞争”。 66

第三层：高性能数据中心 SSD（尤其 Gen6 生态中的“互连+散热+系统”一体化供应链）

理由：性能盘正在从“存储产品”变成“AI 系统吞吐的组成部分”，能用“性能/瓦特”而不是“\$/TB”定价；Micron 对 9650 的叙事已经体现这一点。 16

近线 HDD 的双寡头也具备高现金流属性，但其长期毛利更依赖供给纪律与容量升级节奏；在我乐观的 AI 数据湖假设下，它仍是极具吸引力的“容量价值捕获”。 79

关键变化与拐点：2026 最可能放量的子方向与三大拐点

最可能放量的子方向

HBM4 导入（随 Rubin 上架）：这是一条“确定性最高”的放量路径，因为 Rubin 平台在一手资料中给出 2026H2 的伙伴供货窗口，且 HBM4 已被 SK hynix/Samsung 以量产/出货口径确认。 29

PCIe Gen6 SSD 导入（性能盘先行）：Micron 把 Gen6 SSD 量产与 AI 架构约束绑定，若 2026 下半年 Rubin 系统与更多平台导入 PCIe Gen6，则 2027 会迎来平台扩散。⁸⁰

HAMR HDD 生产部署→扩散：Seagate 已确认生产部署，WD 给出 2026H2 量产与 2027 HAMR 爬坡，2026-2027 将是“容量台阶迭代加速期”。²³

CXL 内存扩展进入“从试点到规模化验证”的窗口：2026 仍可能低渗透，但在 RAG/向量检索等能量化收益的场景下会快速积累案例，形成 2027 之后的放量基础。⁸¹

2026 最可能发生的三个拐点

拐点一：HBM 从“周期品”转向“长协+定制”，价格机制改变

Micron 已明确完成 2026 HBM 供给的价格与数量协议，并推动多年度合同；Samsung 给出 HBM4E sampling 与定制 HBM 采样的时间表。这些信号共同指向：HBM 的价值捕获方式在 2026-2027 会发生质变。⁸²

拐点二：先进封装成为 AI 供应链的“总闸门”，并在 2026 被资本市场重估

TSMC 对 CoWoS 的表述（2026 仍在扩产且供需紧张）意味着封装 slot 将继续决定可交付 GPU 数量，进而影响整个 AI 供应链的交付与定价。⁶⁶

拐点三：电力系统成为“并行产品线”（HVDC 规格化 + BYOG 合规化探索）

OCP Diablo 400 规范把 100kW-1MW 机架供电路径标准化；NVIDIA 把 800VDC 与 2027 Kyber 同步；BYOG 提案则在政策层面探索“以自带发电换取更快 time-to-power”。这三者共同意味着：2026 起，AI 数据中心项目的成败越来越取决于“电力交付能力”，而不是“机房建筑能力”。对存储/内存行业而言，结果会是更强的长协锁量、更高的预付与更集中化的交付节奏。⁸³

¹ ¹⁰ ¹⁴ ¹⁵ ³⁰ <https://developer.nvidia.com/blog/inside-the-nvidia-rubin-platform-six-new-chips-one-ai-supercomputer/>

<https://developer.nvidia.com/blog/inside-the-nvidia-rubin-platform-six-new-chips-one-ai-supercomputer/>

² ¹¹ ²⁴ <https://docs.nvidia.com/gpudirect-storage/>

<https://docs.nvidia.com/gpudirect-storage/>

³ ¹⁸ ²³ ³³ ⁷⁹ <https://investors.seagate.com/news/news-details/2026/Seagate-Delivers-Industrys-Highest-Capacity-Hard-Drives-with-Next-Generation-Mosaic-4/default.aspx>

<https://investors.seagate.com/news/news-details/2026/Seagate-Delivers-Industrys-Highest-Capacity-Hard-Drives-with-Next-Generation-Mosaic-4/default.aspx>

⁴ ¹² ¹⁷ ³⁵ <https://developer.nvidia.com/blog/nvidia-800-v-hvdc-architecture-will-power-the-next-generation-of-ai-factories/>

<https://developer.nvidia.com/blog/nvidia-800-v-hvdc-architecture-will-power-the-next-generation-of-ai-factories/>

⁵ ⁴⁴ ⁶⁶ ⁶⁹ https://investor.tsmc.com/english/encrypt/files/encrypt_file/reports/

[2025-10/6860312f04fd291d0f26b46c1234f84e6332717e/TSMC%203Q25%20Transcript.pdf](https://investor.tsmc.com/english/encrypt/files/encrypt_file/reports/2025-10/6860312f04fd291d0f26b46c1234f84e6332717e/TSMC%203Q25%20Transcript.pdf)

https://investor.tsmc.com/english/encrypt/files/encrypt_file/reports/2025-10/6860312f04fd291d0f26b46c1234f84e6332717e/TSMC%203Q25%20Transcript.pdf

6 7 16 22 37 43 48 57 58 59 61 77 80 <https://www.micron.com/about/blog/storage/ssd/micron-9650-ssd-the-worlds-first-pcie-gen6-ssd-reaches-a-new-shipping-milestone>
<https://www.micron.com/about/blog/storage/ssd/micron-9650-ssd-the-worlds-first-pcie-gen6-ssd-reaches-a-new-shipping-milestone>

8 25 29 38 54 70 <https://nvidianews.nvidia.com/news/rubin-platform-ai-supercomputer>
<https://nvidianews.nvidia.com/news/rubin-platform-ai-supercomputer>

9 41 52 <https://www.reuters.com/world/asia-pacific/samsung-electronics-highlights-progress-hbm4-chip-supply-2026-01-02/>
<https://www.reuters.com/world/asia-pacific/samsung-electronics-highlights-progress-hbm4-chip-supply-2026-01-02/>

13 36 47 50 56 73 76 82 <https://investors.micron.com/static-files/088991c5-a249-4f66-a0a6-258d9b66f3f9>
<https://investors.micron.com/static-files/088991c5-a249-4f66-a0a6-258d9b66f3f9>

19 <https://www.polsinelli.com/publications/mid-atlantic-data-center-energy-regulations>
<https://www.polsinelli.com/publications/mid-atlantic-data-center-energy-regulations>

20 51 <https://news.skhynix.com/2026-market-outlook-focus-on-the-hbm-led-memory-supercycle/>
<https://news.skhynix.com/2026-market-outlook-focus-on-the-hbm-led-memory-supercycle/>

21 39 40 42 46 53 72 <https://news.skhynix.com/sk-hynix-completes-worlds-first-hbm4-development-and-readies-mass-production/>
<https://news.skhynix.com/sk-hynix-completes-worlds-first-hbm4-development-and-readies-mass-production/>

26 27 55 78 <https://news.samsung.com/global/samsung-ships-industry-first-commercial-hbm4-with-ultimate-performance-for-ai-computing>
<https://news.samsung.com/global/samsung-ships-industry-first-commercial-hbm4-with-ultimate-performance-for-ai-computing>

28 <https://www.tomshardware.com/pc-components/dram/industry-preps-cheap-hbm4-memory-spec-with-narrow-interface-but-it-isnt-a-gddr-killer-jedecs-new-sphbm4-spec-weds-hbm4-performance-and-lower-costs-to-enable-higher-capacity>
<https://www.tomshardware.com/pc-components/dram/industry-preps-cheap-hbm4-memory-spec-with-narrow-interface-but-it-isnt-a-gddr-killer-jedecs-new-sphbm4-spec-weds-hbm4-performance-and-lower-costs-to-enable-higher-capacity>

31 https://computeexpresslink.org/wp-content/uploads/2023/12/CXL_3.1-White-Paper_FINAL.pdf
https://computeexpresslink.org/wp-content/uploads/2023/12/CXL_3.1-White-Paper_FINAL.pdf

32 64 https://files.futurememorystorage.com/proceedings/2025/20250806_INDA-202-1_CXL_Consortium.pdf
https://files.futurememorystorage.com/proceedings/2025/20250806_INDA-202-1_CXL_Consortium.pdf

34 49 71 83 <https://www.opencompute.org/blog/realizing-the-open-data-center-ecosystem-vision>
<https://www.opencompute.org/blog/realizing-the-open-data-center-ecosystem-vision>

45 <https://3dfabric.tsmc.com/english/dedicatedFoundry/technology/cowos.htm>
<https://3dfabric.tsmc.com/english/dedicatedFoundry/technology/cowos.htm>

60 74 <https://www.forbes.com/sites/tomcoughlin/2026/02/02/c4q-2025-and-2025-hard-disk-drive-industry-update/>
<https://www.forbes.com/sites/tomcoughlin/2026/02/02/c4q-2025-and-2025-hard-disk-drive-industry-update/>

⁶² <https://www.seagate.com/stories/articles/seagate-delivers-industrys-highest-capacity-hard-drives-with-next-generation-mosaic-4/>

<https://www.seagate.com/stories/articles/seagate-delivers-industrys-highest-capacity-hard-drives-with-next-generation-mosaic-4/>

⁶³ <https://www.westerndigital.com/company/newsroom/press-releases/2026/2026-02-03-western-digital-accelerates-storage-innovation-for-ai-era>

<https://www.westerndigital.com/company/newsroom/press-releases/2026/2026-02-03-western-digital-accelerates-storage-innovation-for-ai-era>

⁶⁵ ⁸¹ https://computeexpresslink.org/wp-content/uploads/2025/10/CXL_Q3-2025-Webinar_FINAL.pdf

https://computeexpresslink.org/wp-content/uploads/2025/10/CXL_Q3-2025-Webinar_FINAL.pdf

⁶⁷ <https://www.reuters.com/technology/thailand-approves-western-digitals-693-mln-investment-project-2024-08-26/>

<https://www.reuters.com/technology/thailand-approves-western-digitals-693-mln-investment-project-2024-08-26/>

⁶⁸ <https://www.seagate.com/innovation/smart-manufacturing-ai/>

<https://www.seagate.com/innovation/smart-manufacturing-ai/>

⁷⁵ <https://www.edn.com/jedec-finalizes-hbm4-standard/>

<https://www.edn.com/jedec-finalizes-hbm4-standard/>